정규세션 4주차 ToBig's 11기 김유민

# **Decision Tree**

의사결정나무

# 0 1 1 nts

Unit 01 | Decision Tree Overview

Unit 02 | The algorithm of growing DT

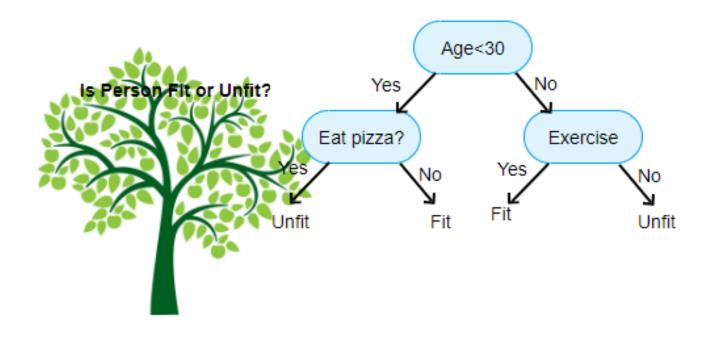
Unit 03 | Tree pruning

Unit 04 | Decision Tree with Sklearn

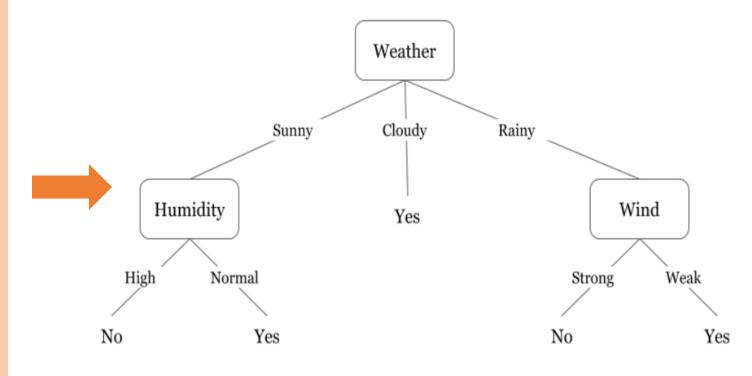








Day	Weather	Temperature	Humidity	Wind	Play?
1	Sunny	80	High	Weak	No
2	Cloudy	66	High	Weak	Yes
3	Sunny	43	Normal	Strong	Yes
4	Cloudy	82	High	Strong	Yes
5	Rainy	65	High	Strong	No
6	Rainy	42	Normal	Strong	No
7	Rainy	70	High	Weak	Yes
8	Sunny	81	High	Strong	No
9	Cloudy	69	Normal	Weak	Yes
10	Rainy	67	High	Strong	No

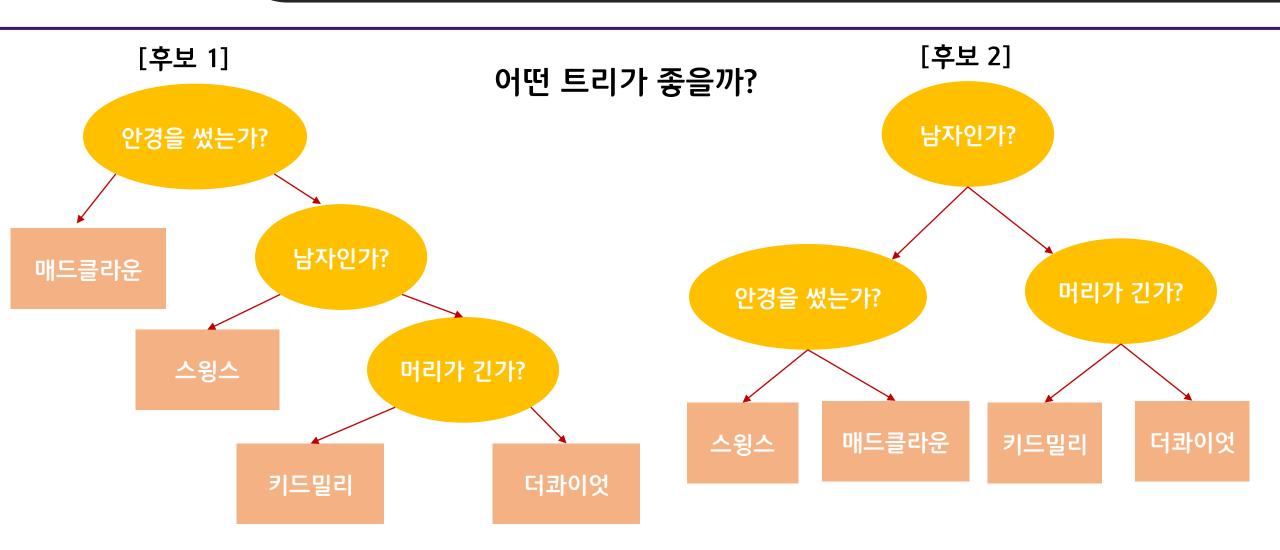


<Training Data>

<Decision Tree Model>

#### **Decision Tree Classifier**

남자	긴 머리	안경	이름
예	아니오	예	매드클라운
예	아니오	아니오	스윙스
아니오	예	아니오	키드밀리
아니오	아니오	아니오	더콰이엇



[후보 1] [후보 2] 어떤 트리가 좋을까?

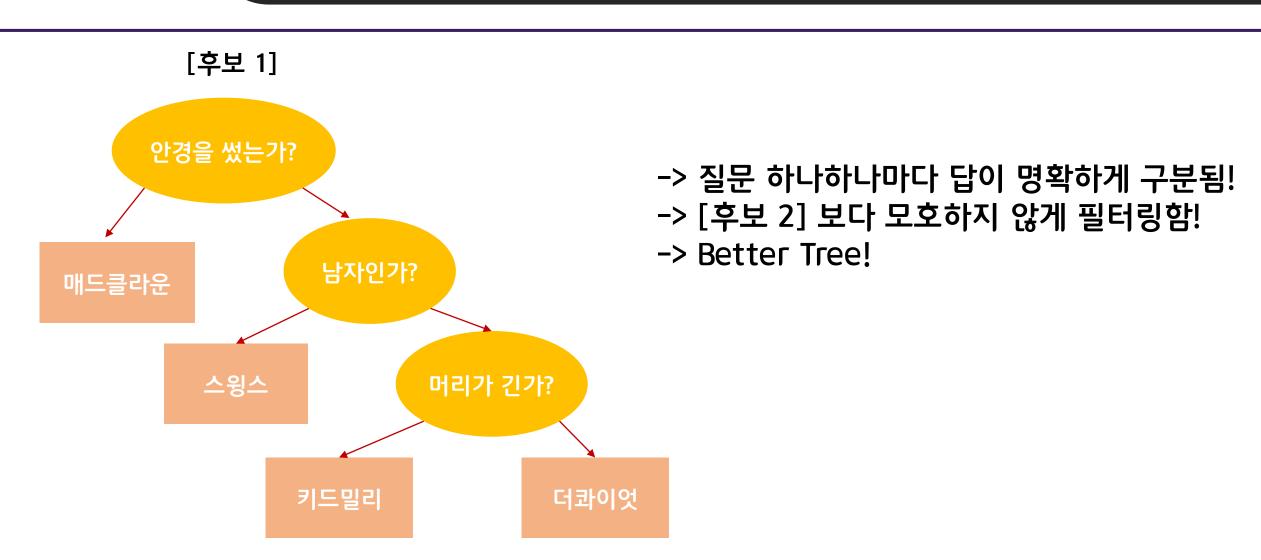
## [판단 기준]

어떤 질문이 가장 많은 해답을 줄 수 있는가?

- ⇒ 어떤 질문이 답의 모호성을 줄여줄 수 있는가?
  - ⇒ 정답과 오답을 얼마나 잘 필터링하는가!

키드밀리

더콰이엇



# 0 1 1 nts

Unit 01 | Decision Tree Overview

Unit 02 | The algorithm of growing DT

Unit 03 | Tree pruning

Unit 04 | Decision Tree with Sklearn

Q1. '모호함(impurity)'을 측정하는 지표?

A. Entropy, Gini Index, Classification error 등

Q2. 어떤 기준으로 노드를 놓아야 하며, 어떤 노드를 가장 위에 놓아야 할까?

A. ID3 & CART 알고리즘으로 판단해!

- Q1. '모호함(impurity)'을 측정하는 지표?
  - A. Entropy, Gini Index, Classification error 등

- Q2. 어떤 기준으로 노드를 놓아야 하며, 어떤 노드를 가장 위에 놓아야 할까?
  - A. ID3 & CART 알고리즘으로 판단해!

용어에 겁먹지 말고 하나하나 차근차근 알아보아요!

ID3 Algorithm

#### ✓ Entropy란?

## A. <mark>'무질서도'</mark>를 정량화해서 표현한 값





High Entropy (messy)

Low Entropy (Clean)

ID3 Algorithm

- ✓ Entropy란?
  - A. <mark>'무질서도'</mark>를 정량화해서 표현한 값
  - -> 어떤 집합의 Entropy가 높을수록 그 집단의 특징을 찾는 것이 어려움
  - -> Decision Tree 잎 노드의 Entropy가 최소가 되는 방향으로 분류하는 것이 최적

$$Entropy = \sum_{i=1}^{n} -p(c_i)log_2(p(c_i))$$

where  $p(c_i)$  is the probability/percentage of class  $c_i$  in a node.

age	income	student	credit_rating	Class: buys_computer
youth	high	no	fair	no
youth	high	no	excellent	no
middle_aged	high	no	fair	yes
senior	medium	no	fair	yes
senior	low	yes	fair	yes
senior	low	yes	excellent	no
middle_aged	low	yes	excellent	yes
youth	medium	no	fair	no
youth	low	yes	fair	yes
senior	medium	yes	fair	yes
youth	medium	yes	excellent	yes
middle_aged	medium	no	excellent	yes
middle_aged	high	yes	fair	yes
senior	medium	no	excellent	no

ID3 Algorithm

Buys\_computer에 대한 Entropy를 구해보자!



ID3 Algorithm

#### 1. ID3

- Entropy를 도입하여 Branch Split을 해보자!
- Information Gain = 전체 Entropy 속성별 Entropy
- Information Gain이 높을수록 명확한 정보를 얻을 수 있음.

$$Gain(A) = Info(D) - Info_A(D_i)$$

$$Info(D) = Entropy_{label}$$

$$Info_A(D_i) = -\sum_{j=1}^{3} \frac{|D_j|}{|D|} * Entropy_{label_j}$$

ID3 Algorithm

















Cartoon? Winter? Many people?

img	cartoon	winter	> 1	Family winter photo
	No	Yes	Yes	Yes
-1	No	Yes	No	No
E Comb	Yes	No	Yes	No
*	Yes	Yes	Yes	No
	No	Yes	No	No
S OF S	No	No	Yes	No
-	Yes	No	Yes	No
1	yes	yes	no	no

ID3 Algorithm

$$Gain(A) = Info(D) - Info_A(D_i)$$

전체 8개 사진

- -> 겨울 가족 사진 Yes 1개
- -> 겨울 가족 사진 No 7개

img	cartoon	winter	>1	Family winter photo	
1	No	Yes	Yes	Yes	
	No	Yes	No	No	
E Carps	Yes	No	Yes	No	
**	Yes	Yes	Yes	No	
	No	Yes	No	No	
Social Contraction	No	No	Yes	No	
-	Yes	No	Yes	No	
*	yes	yes	no	no	

$$Gain(A) = Info(D) - Info_A(D_i)$$
ID3 Algorithm

$$Info_{A}(D_{i}) = -\sum_{j=1}^{2} \frac{|D_{j}|}{|D|} * Entropy_{label_{j}}$$

$$Info(carton) = -\sum_{k=1}^{2} \frac{|D_{k}|}{|D|} \text{ Entropy}_{label_{k}}$$

Into (cartan) = 
$$-\frac{2}{2}\frac{|D_{i}|}{|D|}$$
 Entropylatel:

-. 
$$Gain(cartoon) = 0.543 - 0.408$$
  
= 0.(38

img	cartoon	winter	> 1	Family winter photo
	No	Yes	Yes	Yes
-	No	Yes	No	No
S trins	Yes	No	Yes	No
* P	Yes	Yes	Yes	No
	No	Yes	No	No
S OF SEC.	No	No	Yes	No
-	Yes	No	Yes	No
1	yes	yes	no	no

0.543  $Gain(A) = Info(D) - Info_A(D_i)$ ID3 Algorithm

$$Info_A(D_i) = -\sum_{j=1}^{3} \frac{|D_j|}{|D|} * Entropy_{label_j}$$

Info(winter) =  $-\frac{2}{n=1}\frac{(D_{\overline{n}})}{(D_{\overline{n}})}$  Entropy label. Yes=1, No = 2

- · 101 Entropy abol, = \$ E([1+,4-]) = \$ (-\$ (025 \$ (025) = 0.45)
- · (D2) Entropy (abel, = == (0+,3-1)=== (-3|923 3(923) = 0

... Gain (winter) = 
$$0.543 - 0.45$$
  
=  $0.093$ 

img	cartoon	winter	> 1	Family winter photo
	No	Yes	Yes	Yes
-1	No	Yes	No	No
E Comb	Yes	No	Yes	No
* P	Yes	Yes	Yes	No
	No	Yes	No	No
South.	No	No	Yes	No
T CHE Y	Yes	No	Yes	No
1	yes	yes	no	no

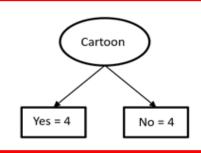
$$Gain(A) = Info(D) - Info_A(D_i)$$

$$Info_A(D_i) = -\sum_{j=1}^3 \frac{|D_j|}{|D|} * Entropy_{label_j}$$

#### ID3 Algorithm

#### Information Gain이 가장 높음!

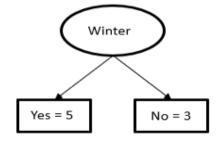
- -> cartoon이냐 아니냐로 branch split했을 때 가장 정보 획득량이 큼
- -> 최초 split "cartoon" column



Information Gain(winter family photo, cartoon)

$$= 0.543 - (4/8 * E([0+,4-]) + 4/8 * E([1+,3-]))$$

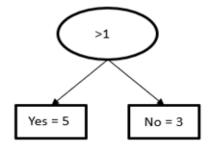
= 0.138



Information Gain(winter family photo, winter)

$$= 0.543 - (5/8 * E([1+,4-]) + 3/8 * E([0+,3-]))$$

= 0.093



Information Gain(winter family photo, >1)

$$= 0.543 - (5/8 * E([1+,4-]) + 3/8 * E([0+,3-]))$$

= 0.093

**CART Algorithm** 

#### 2. CART

- Gini index를 도입하여 Branch Split을 해보자!
- 데이터를 split했을 때 불순한 정도
- 데이터의 대상 속성을 얼마나 잘못 분류할지 계산
- Binary split을 전제로 분석함
- Feature의 데이터 분류 개수가 k개일 때  $2^{k-1} 1$ 개 만큼의 split 생성

Feature "A"에 대해 Gini 계수를 구한다면! (A의 class는 3개)

$$\rightarrow$$

$$Gini(A) = \sum_{j=1}^{2} \frac{|D_j|}{|D|} * Gini(D_i)$$

$$Gini(D_i) = 1 - \sum_{j=1}^{3} P_j$$

age	income	student	credit_rating	Class: buys_computer
youth	high	no	fair	no
youth	high	no	excellent	no
middle_aged	high	no	fair	yes
senior	medium	no	fair	yes
senior	low	yes	fair	yes
senior	low	yes	excellent	no
middle_aged	low	yes	excellent	yes
youth	medium	no	fair	no
youth	low	yes	fair	yes
senior	medium	yes	fair	yes
youth	medium	yes	excellent	yes
middle_aged	medium	no	excellent	yes
middle_aged	high	yes	fair	yes
senior	medium	no	excellent	no

**CART Algorithm**  $Gini_{age}(D)$ Age  $Gini_{credit}(D)$ Credit  $Gini_{income}(D)$ Income Student  $Gini_{student}(D)$ 

이 중 <mark>가장 작은 Gini index값</mark>을 가지는 변수가 최초 split이 될거야!

#### Age에 대한 Gini index를 먼저 구해보자!

	RID	age	income	student	credit_rating	class_buys_computer
0	1	youth	high	no	fair	no
1	2	youth	high	no	excellent	no
7	8	youth	medium	no	fair	no
8	9	youth	low	yes	fair	yes
10	11	youth	medium	yes	excellent	yes

	RID	age	income	student	credit_rating	class_buys_computer
2	3	middle_aged	high	no	fair	yes
3	4	senior	medium	no	fair	yes
4	5	senior	low	yes	fair	yes
5	6	senior	low	yes	excellent	no
6	7	middle_aged	low	yes	excellent	yes
9	10	senior	medium	yes	fair	yes
11	12	middle_aged	medium	no	excellent	yes
12	13	middle_aged	high	yes	fair	yes
13	14	senior	medium	no	excellent	no

#### **CART Algorithm**

#### **CART Algorithm**

#### Gini Index

 $Min(Gini_{age_i}) = 0.357$ 

 $Min(Gini_{income_i}) = 0.443$ 

 $Min(Gini_{credit}) = 0.429$ 

 $Min(Gini_{student}) = 0.367$ 



## Middle\_aged

	age	income	student	credit_rating	class_buys_computer
2	middle_aged	high	no	fair	yes
6	middle_aged	low	yes	excellent	yes
11	middle_aged	medium	no	excellent	yes
12	middle_aged	high	yes	fair	yes

# Youth, senior

	age	income	student	credit_rating	class_buys_computer
0	youth	high	no	fair	no
1	youth	high	no	excellent	no
3	senior	medium	no	fair	yes
4	senior	low	yes	fair	yes
5	senior	low	yes	excellent	no
7	youth	medium	no	fair	no
8	youth	low	yes	fair	yes
9	senior	medium	yes	fair	yes
10	youth	medium	yes	excellent	yes
13	senior	medium	no	excellent	no

**Continuous Feature** 

# Q. 연속형 변수는 어떻게 split하나요?

- 1) 전체 데이터를 모두 기준점으로 하거나,
- 2) 중위수, 사분위수를 기준점으로 하거나,
- 3) Label의 class가 바뀌는 수를 기준점으로!

**Continuous Feature** 

# Step 1. Split할 연속형 변수를 sorting한다.

	ID	STREAM	SLOPE	ELEVATION	VEGETATION
0	1	False	steep	3900	chapparal
1	2	True	moderate	300	riparian
2	3	True	steep	1500	riparian
3	4	False	steep	1200	chapparal
4	5	False	flat	4450	conifer
5	6	True	steep	5000	conifer
6	7	True	steep	3000	chapparal

ELEVATION
300
1200
1500
3000
3900
4450
5000

Continuous Feature

## Step 2. Label의 class가 바뀌는 지점을 찾는다. Step 3. 경계의 평균값으로 기준값을 잡는다.

	ID	STREAM	SLOPE	ELEVATION	VEGETATION
1	2	True	moderate	300	riparian
3	4	False	steep	1200	chapparal
2	3	True	steep	1500	riparian
6	7	True	steep	3000	chapparal
0	1	False	steep	3900	chapparal
4	5	False	flat	4450	conifer
5	6	True	steep	5000	conifer

	ID	STREAM	SLOPE	ELEVATION	VEGETATION	
1	2	True	moderate	300	riparian	750
3	4	False	steep	1200	chapparal	1,35
2	3	True	steep	1500	riparian	225
6	7	True	steep	3000	chapparal	223
0	1	False	steep	3900	chapparal	417
4	5	False	flat	4450	conifer	717
5	6	True	steep	5000	conifer	

Continuous Feature

## Step 4. 구간별 경계값을 기준으로 Entropy 또는 Gini를 산출한다.

$$\begin{aligned} \operatorname{Gain}(elec_{750}) &= \operatorname{Info}(D) - \operatorname{Info}_{elec_{750}}(D) \\ \operatorname{Gain}(elec_{1350}) &= \operatorname{Info}(D) - \operatorname{Info}_{elec_{1350}}(D) \\ \operatorname{Gain}(elec_{2250}) &= \operatorname{Info}(D) - \operatorname{Info}_{elec_{2250}}(D) \\ \operatorname{Gain}(elec_{4175}) &= \operatorname{Info}(D) - \operatorname{Info}_{elec_{4175}}(D) \\ \\ \operatorname{Max}(\operatorname{Gain}(elec)) \end{aligned}$$

**Continuous Feature** 

## Step 5. 최종 Split point 선택!

Stream

0.3

Slope

0.5



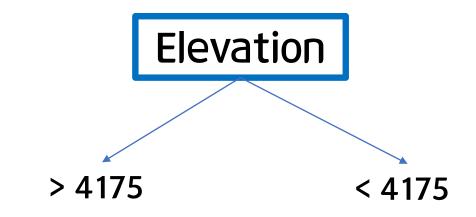
Elevation

750: 0.3

1350: 0.18

2250: 0.59

4175: 0.86



# 0 1 1 nts

Unit 01 | Decision Tree Overview

Unit 02 | The algorithm of growing DT

Unit 03 | Tree pruning

Unit 04 | Decision Tree with Sklearn

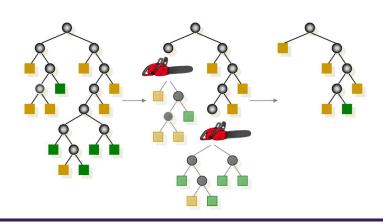
#### Unit 03 | Tree Pruning

**Continuous Feature** 

## ✓ DT의 문제점?

계속 분류하다 보면... 마지막에는 순수 node 탄생

- -> 제한없이 분기를 허용하면 overfitting 발생함
  - + 모델이 너무 복잡해짐
- -> <mark>가지치기(pruning)</mark> 도입



#### Unit 03 | Tree Pruning

# ✓ Pruning

- 1) Pre-pruning(사전 가지치기)
  - 트리의 최대 depth나 분기점의 최소 개수를 미리 지정
- 2) Post-pruning(사후 가지치기 또는 가지치기)
  - 트리를 만든 후 데이터 포인트가 적은 노드를 삭제 or 병합

#### Unit 03 | Tree Pruning

# ✓ DT의 장단점

#### [장점]

- 1. 모델 시각화가 용이함 -> 비전문가도 쉽게 해석 가능!
- 2. 각 특성이 개별적으로 처리되어 데이터 스케일 영향x -> 전처리 필요x
- 3. 특성의 스케일이 서로 다르거나 연속형/범주형 혼합데이터인 경우에도 적용 가능

#### [단점]

1. 가지치기를 해도 과대적합되는 경향이 있음 -> 일반화 성능 bad => 해결방안? Ensemble!

# 0 1 1 nts

Unit 01 | Decision Tree Overview

Unit 02 | The algorithm of growing DT

Unit 03 | Tree pruning

Unit 04 | Decision Tree with Sklearn

#### Unit 04 | Decision Tree with Sklearn

#### ✓ Decision Tree with Sklearn

#### sklearn.tree.DecisionTreeClassifier

class sklearn.tree. DecisionTreeClassifier (criterion='gini', splitter='best', max\_depth=None, min\_samples\_split=2, min\_samples\_leaf=1, min\_weight\_fraction\_leaf=0.0, max\_features=None, random\_state=None, max\_leaf\_nodes=None, min\_impurity\_decrease=0.0, min\_impurity\_split=None, class\_weight=None, presort=False) [source]

Criterion: 트리 성장 알고리즘 ('Entropy' 또는 'gini' 입력) Max\_depth: 트리 깊이 설정(default = None) Min\_samples\_split: 노드 분기할 때 최소 데이터 개수 기준

Min\_samples\_leaf: 리프에 있어야하는 데이터의 최소 개수

Q & A

들어주셔서 감사합니다.

#### Reference

ToBig's 11기 정규세션 Decision Tree 강의(이준걸님) Decision Tree 강의(허민석님) 가천대학교 의사결정나무모델 강의

https://www.youtube.com/watch?v=n0p0120Gxqk

https://www.youtube.com/watch?v=UPKugq0fK04

https://tensorflow.blog/%ED%8C%8C%EC%9D%B4%EC%8D%AC-%EB%A8%B8%EC%8B%A0%EB%9F%AC%EB%8B%9D/2-3-5-%EA%B2%B0%EC%A0%95-%ED%8A%B8%EB%A6%AC/